

Estadística para Economistas

Medidas Características de una Distribución

Wilfredo Bacilio Alarcón

2025-09-04

Section 1

Medidas de centralización

1. Medidas de centralización

Medida de centralización

Las medidas de centralización son valores numéricos que resumen en un solo número el "centro" o "tendencia central" de una distribución de datos.

- Permiten representar un conjunto de datos con un valor característico.
- Complementan a las medidas de dispersión.
- Se dividen en: media, mediana, moda, media geométrica, media armónica.

Media aritmética

La **media aritmética** se define como:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- Representa el punto de equilibrio de los datos.
- Es sensible a valores extremos (outliers).

- ❶ $\sum_{i=1}^n (x_i - \bar{x}) = 0$ (Demostración inmediata de la definición).
- ❷ La media es única.
- ❸ Si todos los valores se incrementan en una constante c , entonces:

$$\bar{x}_{nuevo} = \bar{x} + c$$

- ❹ Si todos los valores se multiplican por una constante k , entonces:

$$\bar{x}_{nuevo} = k \cdot \bar{x}$$

Media Aritmética

- 5 La media $\bar{x}$ es el valor a que minimiza:

$$S(a) = \sum_{i=1}^n (x_i - a)^2$$

La media el valor central que minimiza la suma de los errores cuadrados (o suma de los cuadrados de las desviaciones), es decir, es el valor que más “ajusta” a los datos.

Demostración:

$$\frac{dS}{da} = -2 \sum_{i=1}^n (x_i - a) = -2 \left(\sum_{i=1}^n x_i - na \right) = 0$$

$$\Rightarrow a = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

Mediana

La **mediana** es el valor que divide a los datos ordenados en dos partes de igual tamaño.

Si $X = \{x_1, x_2, \dots, x_n\}$ es un conjunto de datos ordenados, la mediana es:

$$\tilde{x} = \begin{cases} x_{\frac{n+1}{2}}, & \text{si } n \text{ es impar} \\ \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2}, & \text{si } n \text{ es par} \end{cases}$$

- No es afectada por valores extremos.
- Adecuada para distribuciones asimétricas.

Moda

La **moda** es el valor que ocurre con mayor frecuencia en un conjunto de datos.

- Puede no ser única (multimodal).
- Es útil en variables cualitativas.

Media Geométrica y Armónica

Media Geométrica

La **media geométrica** se define como:

$$G = \left(\prod_{i=1}^n x_i \right)^{\frac{1}{n}}, \quad x_i > 0$$

Media Armónica

La **media armónica** se define como:

$$H = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}, \quad x_i > 0$$

- $H \leq G \leq \bar{x}$
- Útiles en tasas, razones y proporciones.

Comparación de Medidas de Centralización

Medida	Fórmula	Propósito	Sensibilidad a Outliers
Media	$\bar{x} = \frac{1}{n} \sum x_i$	Representa el promedio de los datos	Alta
Mediana	$\tilde{x} =$ valor en la pos. central	Divide los datos ordenados en dos mitades	Baja
Moda	No tiene fórmula específica	Valor más frecuente en los datos	Moderada
Media Geom	$G = (\prod_{i=1}^n x_i)^{\frac{1}{n}}$	Promedio multiplicativo, útil en tasas	Alta
Media Arm	$H = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$	Promedio de inversos, útil en ratios	Alta

Section 2

Medidas de dispersión

Medidas de dispersión

Las **medidas de dispersión** nos ayudan a entender cuán dispersos o concentrados están los datos alrededor de un valor central, generalmente la media.

Las principales medidas de dispersión son:

- Rango
- Varianza
- Desviación estándar
- Coeficiente de variación

Rango

El **rango** de un conjunto de datos es la diferencia entre el valor máximo y el valor mínimo.

$$\text{Rango} = \max(X) - \min(X)$$

- Fácil de calcular.
- Sensible a valores extremos (outliers).

Varianza

La **varianza** es una medida que nos indica el promedio de las desviaciones al cuadrado de los datos respecto a la media.

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

Donde:

- x_i es la i -ésima observación.
- μ es la media (poblacional) de los datos.
- La varianza mide la **dispersion** de los datos en relación con su media. Es decir, indica que tan alejados se encuentran los valores observados respecto al valor promedio.

- Para **datos muestrales** la varianza se calcula con la siguiente fórmula:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

el cual es conocido como **varianza muestral** o **cuasivarianza**, donde:

- El denominador $n - 1$ se utiliza para corregir el sesgo en la estimación de la varianza poblacional a partir de una muestra (**corrección de Bessel**), lo que permite que s^2 sea un estimador **insesgado** de la varianza poblacional σ^2 .

Propiedades de la Varianza

- ❶ **La varianza es siempre no negativa.** Formalmente;

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 \text{ y } \sigma^2 \geq 0$$

La varianza será igual a cero solo cuando todos los valores de los datos son iguales a la media (cuando no hay dispersión).

- ❷ **Multiplicar todos los valores en el conjunto de datos se multiplican por una constante c , la varianza se multiplica por c^2 .** Formalmente:

$$\text{Si } x'_i = c \times x_i \text{ para todo } i, \text{ entonces } \sigma'^2 = c^2 \times \sigma^2$$

Esto significa que si se escala la variable por una constante c , la **varianza** se amplifica por el cuadrado de esa constante.

Propiedades de la Varianza

- 3 Incrementar todos los valores en el conjunto de datos por una constante c , la **varianza no cambia**. Formalmente:

$$\text{Si } x'_i = x_i + c, \text{ para todo } i \text{ entonces } \sigma'^2 = \sigma^2$$

La razón de esto es que al sumar una misma constante a todos los datos, la nueva media se desplaza, pero la dispersión de los datos respecto a la nueva media sigue siendo la misma.

- 4 La unidad de la varianza es el cuadrado de la unidad original de los datos, por lo que la **desviación estándar** suele ser más útil para interpretación.

Propiedades de la Varianza

- 5 **La varianza de una constante es 0.** Formalmente:

$$\text{Si } X = c, \text{ entonces } Var(X) = 0$$

Al ser una constante, no hay variabilidad en los datos por lo que no hay dispersión y así la varianza es cero.

- 6 **Varianza de la suma de las variables aleatorias.** Si X y Y son dos variables aleatorias, la varianza de la suma de X e Y es:

$$Var(X + Y) = Var(X) + Var(Y) + 2 \times Cov(X, Y)$$

donde $Cov(X, Y)$ es la **covarianza** entre las variables X e Y .

- Si las dos variables son independientes ($Cov(X, Y) = 0$) la varianza es la suma de las varianzas: $Var(X + Y) = Var(X) + Var(Y)$.

Propiedades de la Varianza

- 7 **Varianza de una combinación lineal.** Si X es una variable aleatoria y a y b son constantes, entonces la varianza de una combinación lineal $aX + b$ es:

$$Var(aX + b) = a^2 \times Var(X)$$

donde:

- Si a es grande, la dispersión de los datos se amplifica. Si a es pequeño, la dispersión disminuye.
 - Esta propiedad es útil cuando se realiza alguna transformación de datos, como en la regresión lineal u otras técnicas de modelado.
- 8 **Varianza de la diferencia de variables aleatorias.** Si X y Y son dos variables aleatorias, la varianza de la diferencia $X - Y$ es:

$$Var(X - Y) = Var(X) + Var(Y) - 2 \times Cov(X, Y)$$

Propiedades de la Varianza

- 9 **Descomposición de la varianza.** La varianza total de una variable aleatoria se puede descomponer en dos componentes: La varianza **explicada** (debido al un modelo) y la varianza **residual** (debido a la aleatoriedad o error), es decir:

$$Var(Y) = Var(\hat{Y}) + Var(\epsilon)$$

donde $\hat{Y}$ es la predicción del modelo y ϵ es el error residual.

- Esta propiedad es útil cuando se busca ajustar el modelo y la precisión de las predicciones.

Propiedades de la Varianza

- 10 **Varianza y correlación.** Si X y Y son dos variables aleatorias, la varianza de una combinación lineal de X e Y , es decir $aX + bY$, puede expresarse como:

$$Var(aX + bY) = a^2 \times Var(X) + b^2 \times Var(Y) + 2ab \times Cov(X, Y)$$

Es decir, la varianza de una combinación lineal de dos variables aleatorias depende de sus varianzas y su correlación. Asimismo:

- Si las variables están altamente correlacionadas, la varianza combinada será mayor.
- Esto nos permite entender cómo la relación entre dos variables afecta a la varianza de su combinación.

Desviación Estándar

Desviación estándar

La **desviación estándar** es la raíz cuadrada de la varianza y proporciona una medida de dispersión con las mismas unidades que los datos originales.

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}$$

- Es más fácil de interpretar que la varianza, ya que sus unidades son las mismas que las de los datos originales.
- Cuando trabajamos con **datos muestrales**, la desviación estándar se utiliza comúnmente para medir la dispersión de los datos alrededor de la media muestral.

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Propiedades de la Desviación Estándar

- 1 La desviación estándar también es **no negativa**.
- 2 Es sensible a los valores extremos, igual que la varianza.
- 3 Si todos los valores en los datos se multiplican por una constante c , la desviación estándar se multiplica por c .

Coeficiente de Variación

Coeficiente de Variación

El **coeficiente de variación** (CV) es una medida relativa de dispersión que expresa la desviación estándar como un porcentaje de la media.

$$CV = \frac{\sigma}{\mu} \times 100$$

- Es útil cuando se desea comparar la dispersión relativa entre conjuntos de datos que pueden tener unidades de medida diferentes o medias distintas.
- Al normalizar la desviación estándar con respecto a la media, el CV permite hacer comparaciones directas entre datos que, de otro modo, no serían comparables debido a las diferencias en su escala o magnitud.
- Con datos muestrales, usamos:

$$CV = \frac{s}{\bar{x}} \times 100$$

Comparación de Medidas de Dispersión

Medida	Fórmula	Propósito	Sensibilidad a Outliers
Rango	$\max(X) - \min(X)$	Medir la diferencia entre extremos	Alta
Varianza	$\frac{1}{n} \sum (x_i - \mu)^2$	Medir la dispersión total	Alta
Desviación Estándar	$\sqrt{\sigma^2}$	Medir dispersión en las mismas unidades que los datos	Alta
Coeficiente de Variación	$\frac{\sigma}{\mu} \times 100$	Medir dispersión relativa	Moderada

Section 3

Medidas de forma

3. Medidas de forma

Las **medidas de forma** describen la **simetría** o **asimetría** de una distribución de datos, y la **aplanamiento** de la distribución (curtosis).

Se dividen en:

- **Medidas de simetría y asimetría** (Sesgo)
- **Medidas de curtosis** (Aplanamiento)

Medidas de Simetría y Asimetría (Sesgo)

Asimetría

El **sesgo** (o **asimetría**) mide la **asimetría** de la distribución de los datos alrededor de su media. Es decir, describe si la distribución de los datos tiene una cola más **larga** en uno de los lados de la media.

Medidas de Simetría y Asimetría (Sesgo)

El **coeficiente de asimetría** (γ_1) se calcula como:

$$\gamma_1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)^{3/2}}$$

Donde:

- $\bar{x}$ es la media de los datos.
- Si $\gamma_1 = 0$, la distribución es **simétrica**.
- Si $\gamma_1 > 0$, la distribución tiene **asimetría positiva** (sesgo hacia la derecha).
- Si $\gamma_1 < 0$, la distribución tiene **asimetría negativa** (sesgo hacia la izquierda).

Medidas de Simetría y Asimetría (Sesgo)

Observaciones sobre el Sesgo:

- **Sensibilidad:** El coeficiente de asimetría es **sensible** a los **valores extremos** o **outliers**, ya que estos afectan la forma de la distribución y, en consecuencia, la asimetría.
- **Robustez:** No es muy robusto a los outliers, por lo que para distribuciones con valores atípicos es mejor usar otras medidas.
- **Tipo de Datos:** Es recomendable usar el sesgo con datos **cuantitativos continuos**. Para datos cualitativos, el sesgo no tiene sentido.
- **Aplicaciones:** El sesgo se usa para verificar si los datos siguen una distribución simétrica (como la normal) o si tienen una distribución sesgada, lo que puede afectar análisis posteriores (por ejemplo, inferencia estadística o regresión).

Propiedades del Coeficiente de Asimetría

- 1 **Distribución Simétrica:** $\gamma_1 = 0$
- 2 **Distribución Asimétrica Positiva:** $\gamma_1 > 0$ (Sesgo hacia la derecha)
- 3 **Distribución Asimétrica Negativa:** $\gamma_1 < 0$ (Sesgo hacia la izquierda)
- 4 El **sesgo** es sensible a **valores extremos**.
- 5 El coeficiente de asimetría es **sin unidades**, ya que depende de la forma de la distribución y no de las unidades de los datos.

Curtosis

La **curtosis** mide el grado de **aplanamiento** de una distribución, comparándola con una distribución normal. La curtosis nos ayuda a entender si las colas de la distribución son **más gruesas o más delgadas** que las de una distribución normal.

Medidas de Curtosis

La **curtosis** se calcula como:

$$\gamma_2 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)^2} - 3$$

Donde:

- γ_2 es la **curtosis**.
- Si $\gamma_2 = 0$, la distribución tiene una **curtosis normal** (como la distribución normal estándar).
- Si $\gamma_2 > 0$, la distribución es **leptocúrtica** (pico alto, colas más gruesas).
- Si $\gamma_2 < 0$, la distribución es **platicúrtica** (pico bajo, colas más delgadas).

Observaciones sobre la Curtosis:

- **Sensibilidad:** La curtosis es **sensible** a la forma de las **colas** de la distribución. Si hay valores atípicos en las colas, afectará significativamente el valor de la curtosis.
- **Robustez:** Similar al sesgo, la curtosis no es robusta ante **outliers** y puede dar una falsa impresión de la forma de la distribución si los datos tienen valores extremos.
- **Tipo de Datos:** Se debe usar con **datos cuantitativos continuos**, especialmente cuando se está interesado en la forma de las colas de la distribución.
- **Aplicación:** La curtosis es útil para **detectar distribuciones con colas gruesas** (riesgo en finanzas, distribuciones de ingresos) o para identificar si una distribución tiene colas más ligeras de lo esperado (por ejemplo, en análisis de fiabilidad o en algunos tipos de modelado de eventos).

Propiedades de la Curtosis

- 1 **Curtosis Normal:** $\gamma_2 = 0$ (distribución normal).
- 2 **Curtosis Leptocúrtica:** $\gamma_2 > 0$ (pico más alto que la normal, colas más gruesas).
- 3 **Curtosis Platicúrtica:** $\gamma_2 < 0$ (pico más bajo que la normal, colas más delgadas).
- 4 La curtosis mide **la altitud de las colas** de la distribución.
- 5 La curtosis es **sin unidades** ya que se calcula sobre las desviaciones cuadradas de los datos.

Comparación de Medidas de Forma

Medida	Fórmula	Propósito	Interpretación
Asimetría	$\gamma_1 = \frac{\frac{1}{n} \sum (x_i - \bar{x})^3}{\left(\frac{1}{n} \sum (x_i - \bar{x})^2\right)^{3/2}}$	Medir la simetría de la distribución	$\gamma_1 = 0$ simétrica, $\gamma_1 > 0$ sesgo positivo, $\gamma_1 < 0$ sesgo negativo
Curtosis	$\gamma_2 = \frac{\frac{1}{n} \sum (x_i - \bar{x})^4}{\left(\frac{1}{n} \sum (x_i - \bar{x})^2\right)^2} - 3$	Medir el “aplanamiento” de la distribución	$\gamma_2 = 0$ normal, $\gamma_2 > 0$ leptocúrtica, $\gamma_2 < 0$ platicúrtica

Section 4

Medida de Concentración

Las **medidas de concentración** se utilizan para medir la desigualdad en la distribución de una variable, como los ingresos, la riqueza o el consumo. Las dos principales medidas de concentración son:

- 1 **Curva de Lorenz**
- 2 **Índice de Concentración de Gini**

Curva de Lorenz

La **Curva de Lorenz** es una representación gráfica de la distribución acumulada de una variable, como ingresos o riqueza, que permite observar el grado de concentración o desigualdad en la distribución.

La curva se construye ordenando los datos de menor a mayor y luego representando la proporción acumulada de la variable en el eje vertical y la proporción acumulada de la población en el eje horizontal.

Curva de Lorenz

La **Curva de Lorenz** se construye utilizando los siguientes pasos:

- 1 Ordenar los datos $(x_1, x_2, \dots, x_n)$ de menor a mayor.
- 2 Calcular las **proporciones acumuladas** de los ingresos y de la población.
- 3 Graficar la proporción acumulada de la población $P(x)$ en el eje horizontal y la proporción acumulada de los ingresos $I(x)$ en el eje vertical.

La curva muestra la desigualdad, con la línea diagonal (o línea de igualdad) representando una distribución **perfectamente equitativa**.

Observaciones sobre la Curva de Lorenz:

- **Sensibilidad:** Es sensible a la **desigualdad en la distribución**. Una distribución más desigual se aleja más de la línea de igualdad.
- **Robustez:** La curva de Lorenz no es robusta a **valores extremos**, ya que su forma se ve influenciada por la distribución de los datos.
- **Aplicación:** Se usa para visualizar y comparar la desigualdad en **ingresos** o **riqueza** en diferentes poblaciones, o para cualquier variable que se pueda acumular y comparar de esta manera.
- **Tipo de Datos:** Es adecuada para **datos distribuidos de manera desigual** como ingresos, riqueza o consumo, pero no se utiliza para datos simétricos o homogéneos.

Índice de Concentración de Gini

Índice de Gini

El **Índice de Gini** es una medida numérica de desigualdad basada en la Curva de Lorenz. Mide la **desviación** de la distribución observada respecto a una distribución **perfectamente equitativa** (en la que todos los individuos tendrían la misma cantidad).

El índice de Gini se define como:

$$G = \frac{A}{A + B}$$

Donde:

- A es el área entre la línea de igualdad y la Curva de Lorenz.
- B es el área debajo de la Curva de Lorenz.

Índice de Concentración de Gini

El índice de Gini también se puede calcular a partir de los **coeficientes acumulados** de la distribución:

$$G = 1 - 2 \sum_{i=1}^n (P_i \cdot Q_i)$$

Donde:

- P_i es la proporción acumulada de la población.
- Q_i es la proporción acumulada de la variable de interés (como ingresos).

Índice de Concentración de Gini

Observaciones sobre el Índice de Gini:

- **Sensibilidad:** El índice de Gini es **sensible** a la **desigualdad**. Cuanto mayor sea el índice de Gini, mayor será la desigualdad en la distribución.
- **Robustez:** El índice de Gini es **relativamente robusto** frente a **valores extremos** porque se basa en la comparación relativa de las proporciones acumuladas, no en los valores individuales.
- **Aplicación:** El índice de Gini se usa ampliamente en **economía** y **sociología** para medir la desigualdad de ingresos, riqueza, y distribución del consumo, entre otras.
- **Tipo de Datos:** Es adecuado para datos de **distribuciones acumuladas**, como los **ingresos** o **riqueza**, y mide desigualdad en variables cuantitativas.

Propiedades del Índice de Gini

- ① **Valor 0:** Si todos los individuos tienen la misma cantidad (distribución perfectamente equitativa), $G = 0$.
- ② **Valor 1:** Si toda la riqueza está concentrada en un solo individuo (distribución perfectamente desigual), $G = 1$.
- ③ **Valores intermedios:** Un índice de Gini de 0.3 indica una desigualdad moderada, mientras que valores cercanos a 0.5 o más indican una desigualdad más alta.

Índice de Concentración de Gini

Medida	Fórmula	Propósito	Sensibilidad a Outliers
Curva de Lorenz	Gráfica de las proporciones acumuladas	Visualizar la desigualdad en la distribución	Sensible a valores extremos
Índice de Gini	$G = \frac{A}{A+B}$	Medir la desigualdad numéricamente	Relativamente robusto a outliers

Section 5

Aplicaciones en R